

# Technologies du Web

Laure Soulier — laure.soulier@lip6.fr  
Slides de Ludovic DENOYER

UPMC

31 janvier 2017

### Historique

- NoSQL : Not Only SQL
- 2004 : Big Table Google
- 2008 : Cassandra Facebook
- 2009 : lancement d'une communauté de développement logiciels open source NoSQL

### Spécificités

- Manipulation de données peu (pas) structurées, schéma flexible, sans modèle pré-défini
- Manipulation de données volumineuses
- Haute disponibilité
- Capacités élevées de lectures/écritures

# SQL vs. NoSQL

	<b>Système SQL</b>	<b>Système NoSQL</b>
<b>Finalité</b>	Système de gestion de bases de données	Système de gestion de données
<b>Indépendance données/ programmes</b>	Garantie (séparation du niveau logique/physique)	Non garantie
<b>Schéma des données</b>	Prédéfini, relativement fixe, peu flexible	Pas besoin de fixer le schéma, schéma dynamique, schema-less, schema-later
<b>Eclatement/répartition des données</b>	Eclatement en respect du principe de normalisation, choix de la répartition des données difficile	Principe de proximité physique des données reliées logiquement
<b>Transaction</b>	Respect des propriétés ACID	Relâchement des propriétés ACID
<b>Valeurs d'attributs</b>	Trois états : vrai, faux, NULL	Variable : pas de valeurs, pas d'état NULL, ...

## NoSQL

NoSQL (Not Only SQL), apparu en 2009, et comme son nom l'indique une alternative au langage SQL et au modèle relationnel de base de données que vous avez l'habitude d'utiliser. L'idée est de proposer une architecture souple et puissante avec une forte disponibilité et de faibles contraintes.

Particulièrement à la mode, la majorité des grandes entreprises du web abandonnent leurs bases de données traditionnelles et portent leur propre projet NoSQL : Facebook et Twitter utilisent Cassandra (de la Fondation Apache), Amazon SimpleDB, LinkedIn Voldemort, etc.

# Théorème CAP

Propriétés fondamentales pour les systèmes distribués

- Coherence : tous les nœuds du système voient exactement les mêmes données au même moment
- Availability (Disponibilité) : garantie que toutes les requêtes reçoivent une réponse ;
- Partition tolerance (Résistance au partitionnement) : sauf coupure totale du système, aucune panne ne peut empêcher le système de fonctionner normalement

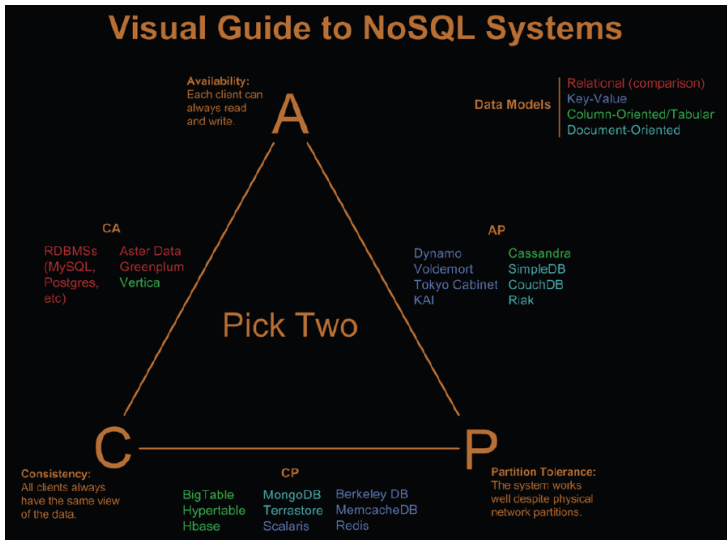
Dans un système distribué, seules deux propriétés sur trois peuvent être assurées à un instant  $t$ .

## Exemples (wikipedia)

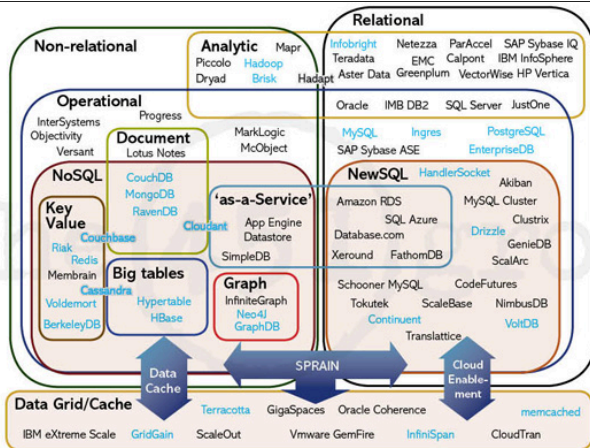
Soit A et B deux utilisateurs, soit N1 et N2 deux nœuds.

- Si A modifie une valeur sur N1, alors pour que B voie cette valeur sur N2 il faut attendre que N1 et N2 soient synchronisés (cohérence).

*Exemple d'arbitrage* : deux utilisateurs qui font une même recherche peuvent obtenir des résultats différents, mais cet inconvénient est moins grave que de ne pas avoir de résultats du tout.



# Typologie des modèles de données NoSQL



[http://blogs.the451group.com/information\\_management/2011/04/15/nosql-newsql-and-beyond/](http://blogs.the451group.com/information_management/2011/04/15/nosql-newsql-and-beyond/)

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données clé-valeur (1/4)

- Similaire à un tableau associatif / table de hachage
- Clé : permet d'accéder à la valeur
- Valeur :
  - Simple chaîne de caractères ou objet sérialisé
  - Absence de structure ou de typage

Clé	Valeur
k1	v1
k2	v2
...	...

Exemples :

- Réseaux sociaux :  
id utilisateur → liste de ses amis
- Livres :  
Id livre → informations (auteur, éditeur, ...)
- Journaux  
Date → liste des évènements



# Typologie des modèles de données NoSQL

---

## ❑ Bases de données clé-valeur (2/4)

- Opérations (CRUD)
  - Create : Création d'un nouvel objet
  - Read : Lecture d'un objet à partir de la clé
  - Update : Mise à jour d'une valeur à partir de la clé
  - Delete : Suppression d'un objet à partir de la clé
- Indexation
  - Index primaire sur la clé
  - Pas d'indexation secondaire (autres attributs)

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données clé-valeur (3/4)

- Avantages

- Performance élevée en lecture et écriture
- Modèle de données simple
- Passage à l'échelle facile

- Inconvénients

- Interrogation limitée : obligation de connaître la clé
- Structure trop simple pour les données complexes
- Complexité déportée sur l'application : les traitements faits de la requête SQL doivent maintenant être faits par l'application

- Solutions : Amazon Dynamo, FoundationDB, Redis, Riak, ...



# Typologie des modèles de données NoSQL

---

## ❑ Bases de données clé-valeur (4/4)

- Exemple :

Gestion du serveur 'azteka' de la fac avec redis



- Créer un objet : stocker le nom du serveur  
`SET server:name "azteka"`
- Lire l'objet : récupérer le nom du serveur  
`GET server:name` → "azteka "
- Supprimer un objet  
`DEL server:name`
- Modification d'un objet :  
`SET server:name "azteka2"` → écrase la valeur précédente

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées colonne (1/5)

- Modèle le plus d'un SGDB relationnel
- Nombre de colonnes dynamiques (pas de valeurs nulles)
- Une « clé cachée » (*rowkey*) pour chaque objet, triée par ordre lexicographique
- Les colonnes sont traitées indépendamment
- Les lignes peuvent être reconstituées plus tard

# Typologie des modèles de données NoSQL

## ❑ Bases de données orientées colonne (2/5)

Nom (2Go)	Note (1Go)
Durand	10
Dupond	15
Dupoint	14

BD orientée ligne :

1:Durand,10 ; 2:Dupond,15 ; 3:Dupoint,14

BD orientée colonne :

Durand:1 ; Dupond:2 ; Dupoint:3

10:1 ; 15:2 ; 14:3

→ Traitement par tableau des valeurs de colonnes

→ Améliore les performances lorsque traitement sur un nombre réduit de colonnes

Exemple : Moyenne des notes

- BD orientée ligne : chargement de toute la table (3Go)

- BD orientée colonne : chargement de l'attribut Note (1Go)

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées colonne (3/5)

- Terminologie :

- Clés
  - » Point d'entrée de la donnée.
- Familles de colonnes
  - » Structure définie
  - » Regroupement par lignes de plusieurs colonnes
  - » Utilisées pour l'indexation, par exemple
- Colonnes
  - » Entités de base (attribut)
  - » Associées à une paire clé-valeur
  - » Pas de structure du schéma de la valeur
- Timestamp
  - » Associé aux colonnes
  - » Gestion de la cohérence de la BD par rapport aux versions

- Pour accéder à une donnée

Clé → Famille → Colonne → Timestamp (par défaut : le plus récent)

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées colonne (4/5)

- Avantages
  - Bon passage à l'échelle
  - Indexation naturelle (colonnes)
  - Gestion des versions → résultats en temps réels
- Inconvénients
  - Lecture difficile pour les données complexes
  - Maintenance : ajout/suppression/regroupement des colonnes
  - Les requêtes dépendent des données
- Solutions : Hbase (Open Source de BigTable utilisé par Google), Cassandra (Facebook), Hyperbase (Amazon)



# Typologie des modèles de données NoSQL

## ❑ Bases de données orientées colonne (5/5)

- Exemple :

- Définir la structure de la table

```
CREATE 'serveurs', {NAME => 'nom', VERSIONS => 3}, {NAME => 'config',  
VERSIONS => 2}, {SPLITS => ['1000','2000','3000','4000']}
```

- Créer un objet : stocker le serveur azteka

```
PUT 'serveurs', '1', 'nom', 'azteka', 'admin:nom', 'soulhier', 'config', 'unix'
```

- Lire l'objet : récupérer le nom du serveur tel qu'il a été inséré lors de la version 1

```
GET 'serveurs', '1', {COLUMN => 'nom', VERSIONS = 1}
```

- Supprimer un objet

```
DELETEALL 'serveurs', '1'
```

- Suppression de la table (désactivation, puis suppression)

```
DISABLE 'serveurs'
```

```
DROP 'serveurs'
```





# Typologie des modèles de données NoSQL

## ❑ Bases de données orientées document (1/3)

- Stockage d'une collection de documents
- Basé sur les paires clés-valeurs
  - Clé : identifie le document
  - Valeur : document en format semi-structuré hiérarchique (XML, JSON)

### • Exemple de fichier JSON

```
{  
  "card": "2",  
  "numbers": {  
    "Conway": [1, 11, 21],  
    "Fibonacci": [0, 1]  
  }  
}
```

### • Exemple de fichier XML

```
<xml>  
  <card>2</card>  
  <numbers>  
    <Conways>  
      <Conway>1</Conway>  
      <Conway>11</Conway>  
      <Conway>21</Conway>  
    </Conways>  
    <Fibonacci>  
      <Fibonacci>0</Fibonacci>  
      <Fibonacci>1</Fibonacci>  
    </Fibonacci>  
  </numbers>  
</xml>
```

# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées document (2/3)

- Avantages
  - Modèle de données simple mais puissant (documents hiérarchiques)
  - Pas de maintenance pour l'ajout/suppression des documents
  - Requêtes assez complexes (simplifie l'application)
- Inconvénients
  - Lenteur pour les grandes requêtes
  - Interconnexion des données difficile
- Solutions : MongoDB, CouchDB, CouchBase



Copyright L.Tamine-Lechani & L. Soulier



# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées document (3/3)

- Exemple avec mongoDB

- Création d'une collection (table en SGBDR)

```
db.createCollection("macollection")
```

- Insertion d'un document

```
db.macollection.insert({'id': '1', titre: 'cours M2', année: '2014-2015'})
```

- Lecture d'un document

```
db.macollection.find({}, {'titre': 'cours M2'})
```

- Mise à jour d'un document

```
db.macollection.update({'titre': 'cours M2'}, {'$set': {'année': '2015-2016'}})
```

- Suppression d'un document

```
db.macollection.remove({'titre': 'cours M2'})
```

- Suppression d'une collection



```
db.macollection.drop()
```



# Typologie des modèles de données NoSQL

## ❑ Bases de données orientées graphe (1/3)

- Stockage de données complexes avec des relations
- Basé sur la théorie des graphes
  - Nœuds : moteur de stockage
  - Relations : description des arcs
- Application : traitement des données des réseaux sociaux



# Typologie des modèles de données NoSQL

---

## ❑ Bases de données orientées graphe (2/3)

- Avantages
  - Modèle de données puissant
  - Stockage et requêtage efficace pour les données complexes et interconnectées
- Inconvénients
  - Fragmentation difficile
- Solutions : Neo4j, OrientDB, InfiniteGraph, ...



# Typologie des modèles de données NoSQL

## □ *Bases de données orientées graphe (3/3)*

- Exemple avec Neo4j



- Création d'un nœud

```
CREATE n = {nom : 'Milou', ville : 'Paris'};
```

- Lecture d'un nœud

```
START n=node(1) return n;
```

- Création d'un nœud avec une relation

```
START Milou = node(1)
```

```
CREATE
```

```
  Tintin = {nom : 'Tintin', ville : 'Paris'},
```

```
  Castafiore = {nom : 'Castafiore', ville : 'Paris'},
```

```
  Milou-[r:AMI]->Tintin
```

```
RETURN
```

```
  Tintin;
```

## MongoDB (Wikipédia)

MongoDB est un système de gestion de base de données :

- orientée documents,
- libre,
- montant bien en puissance (scalable),
- à performance raisonnable,
- ne nécessitant pas de schéma prédéfini des données,
- écrit avec le langage de programmation C++.

Il fait partie de la mouvance NoSQL et vise à fournir des fonctionnalités avancées. Utilisée par Foursquare, bit.ly, Doodle, Disqus

# MongoDB





## Autres propriétés

- Document-oriented storage
- Full Index Support
- Replication & High Availability
- Auto-Sharding
- Querying
- Rich, document-based queries.
- Map/Reduce
- GridFS
- Commercial Support

## Drivers

- C
- C++
- Erlang
- Haskell
- Java
- Javascript
- .NET (C# F#, PowerShell, etc)
- Perl
- PHP
- Python
- Ruby
- Scala

# MongoDB : Principes

- Une instance de MongoDB peut contenir une ou plusieurs bases de données
- Une base de données peut avoir une ou plusieurs **collections**
  - ▶ Équivalent des tables dans les bases classiques
- Une collection peut avoir de zéro à plusieurs **documents**
  - ▶ Les documents d'une même collection n'ont pas obligatoirement le même "schéma" (champs)
  - ▶ Les documents correspondent aux enregistrements (tuples)
  - ▶ Des documents peuvent contenir des documents (structure hiérarchique)
  - ▶ Chaque document possède une clé unique
- MongoDB stocke l'information au format BSON (Binary JSON)

# MongoDB : Propriétés


## Avantages

- Requêtes "faciles"
- Fait sens avec la plupart des applications Web
- Facilité d'intégration des données

## Inconvénients

Pas bien adapté pour les systèmes transactionnels complexes

# MongoDB



# MongoDB

Un document :

```
user = {  
  name: "Z",  
  occupation: "A scientist",  
  location: "New York"  
}
```

# MongoDB

Un document :

```
{  
  " name ": " John Smith ",  
  " address ": {  
    " street ": " Lily Road ",  
    " number ": 32,  
    " city ": " Owatonna ",  
    "zip ": 55060  
  },  
  " hobbies ": [ " yodeling ", "ice skating " ]  
}
```

# MongoDB

Une collection :

```
{ "_id": ObjectId("4efa8d2b7d284dad101e4bc9"),  
  "Last Name": "DUMONT",  
  "First Name": "Jean",  
  "Date of Birth": "01-22-1963" },
```

Obligatory, and  
automatically  
generated by  
MongoDB

```
{ "_id": ObjectId("4efa8d2b7d284dad101e4bc7"),  
  "Last Name": "PELLERIN",  
  "First Name": "Franck",  
  "Date of Birth": "09-19-1983",  
  "Address": "1 chemin des Loges",  
  "City": "VERSAILLES" }
```



# MongoDB

Imaginons que l'on veuille modéliser un blog :

## Mauvais design

```
post = {
  id: 150,
  author: 100,
  text: 'This is a pretty awesome post.',
  comments: [100, 105, 112]
}
author = {
  id: 100,
  name: 'Michael Arrington'
  posts: [150]
}
comment = {
  id: 105,
  text: 'Whatever this sux.'
```

## Autre design

```
post = {  
  author: 'Michael Arrington',  
  text: 'This is a pretty awesome post.',  
  comments: [  
    'Whatever this post sux.',  
    'I agree, lame!'  
  ]  
}
```

Pourquoi celui-ci est-il meilleur ?

```
location1 = {  
  name: "10gen HQ",  
  address: "17 West 18th Street 8th Floor",  
  city: "New York",  
  zip: "10011",  
  latlong: [40.0,72.0],  
  tags: ["business", "cool place"],  
  tips: [  
    {user:"nosh", time:6/26/2010, tip:"stop by for office hours on  
      Wednesdays from 4-6pm"},  
    {.....},  
  ]  
}
```

## Example queries:

- `db.locations.find({latlong:{$near:[40,70]}})`
- `db.locations.find({zip:"10011", tags:"business"})`
- `db.locations.find({zip:"10011"}).limit(10)`

# MongoDB

```
user1 = {  
  name: "nosh"  
  email: "nosh@10gen.com",  
  .  
  .  
  .  
  checkins: [{ location: "10gen HQ",  
    ts: 9/20/2010 10:12:00,  
    ...},  
    ...  
  ]  
}
```

- SQL

- `INSERT INTO t (fn, ln) VALUES ('John', 'Doe')`

- MongoDB

- `db.t.insert({fn:'John', ln: 'Doe'})`

- SQL

- `UPDATE t SET ln='Smith' WHERE ln='Doe'`

- MongoDB

- `db.t.update({ln:'Doe'},{$set:{ln:'Smith'}})`

- Only 1 doc. is updated by default
  - Specify `{multi:true}` for multi-doc updates

- `db.t.update({ln:'Doe'},{$set:{ln:'Smith'}},{multi:true})`

- SQL
  - `DELETE FROM t WHERE fn='John'`
- MongoDB
  - `db.t.remove({fn:'John'})`

- SQL
  - `DROP TABLE t`
- MongoDB
  - `db.t.drop()`



- SQL

- `SELECT * FROM t`

- MongoDB

- `db.t.find()`

- SQL

- `SELECT id, name FROM t`

- MongoDB

- `db.t.find({}, {name:1})`

- SQL

- `SELECT * FROM t WHERE fn='John'`

- MongoDB

- `db.t.find({ln:'John'})`

- SQL

- `SELECT id, age FROM t WHERE fn='John' AND ln='Smith'`

- MongoDB

- `db.t.find({fn:'John',ln:'Smith'},{age:1})`

- SQL

```
- SELECT country FROM t  
WHERE fn='John'  
  
ORDER BY age DESC LIMIT 10
```

- MongoDB

```
- db.t.find(  
  {fn:'John'},  
  {country:1, _id:0}  
) .sort({age:1}) .limit(10)
```

- SQL

- `SELECT fn,ln FROM t`  
`WHERE age > 30`

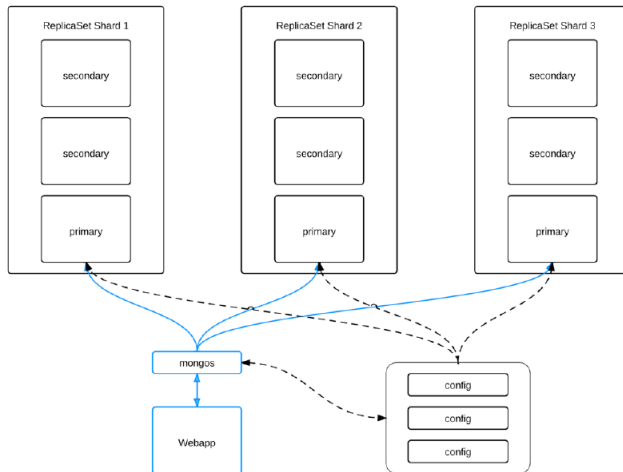
- MongoDB

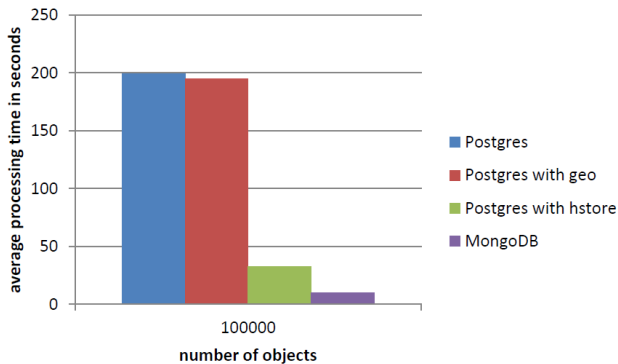
- `db.t.find(`  
`{age:{$gt:30}},`  
`{fn:1, ln:1, _id:0}`  
`)`

# Sharding


- Le sharding consiste en la répartition des données en plusieurs instances de bases de données, selon un critère donné.
- La montée en charge horizontale est plus simple à mettre en oeuvre : il est plus facile et moins coûteux d'acheter de nouveaux serveurs plutôt que d'augmenter la capacité d'un seul serveur.
- Un shard est un serveur mongo normal : il peut contenir des collections shardées ou non, et peut faire partie d'un replica set.
- Il est important de bien choisir ses critères de sharding pour éviter une trop grande disparité.

# MongoDB






# MongoDB





# MongoDB



## Nouvelle Connexion

```
1 import com.mongodb.Mongo;
2 import com.mongodb.DB;
3 import com.mongodb.DBCollection;
4 import com.mongodb.BasicDBObject;
5 import com.mongodb.DBObject;
6 import com.mongodb.DBCursor;
7
8 Mongo m = new Mongo();
9 // or
10 Mongo m = new Mongo( "localhost" );
11 // or
12 Mongo m = new Mongo( "localhost" , 27017 );
13
14 DB db = m.getDB( "mydb" );
```

Le Pooling de connection est automatiquement géré

## Authentication (optionnel)

```
boolean auth = db.authenticate(myUserName, myPassword);
```

## Liste des collections (tables)

```
1 Set<String> colls = db.getCollectionNames();  
2  
3 for (String s : colls) {  
4     System.out.println(s);  
5 }
```

## Utilisation des collections (tables)

```
DBCollection coll = db.getCollection("testCollection")
```

## Insertion

```
{  
  "name" : "MongoDB",  
  "type" : "database",  
  "count" : 1,  
  "info" : {  
    x : 203,  
    y : 102  
  }  
}
```

## Insertion

```
BasicDBObject doc = new BasicDBObject();

doc.put("name", "MongoDB");
doc.put("type", "database");
doc.put("count", 1);

BasicDBObject info = new BasicDBObject();

info.put("x", 203);
info.put("y", 102);

doc.put("info", info);

coll.insert(doc);
```

## Requête

```
DBObject doc = collection.findOne(); //get first document  
System.out.println(dbObject);
```



## Requête

```
1 DBCursor cursor = collection.find();  
2 while(cursor.hasNext()) {  
3     System.out.println(cursor.next());  
4 }
```

## Requête

```
1 BasicDBObject query = new BasicDBObject();  
2 query.put("number", 5);  
3 DBCursor cursor = collection.find(query);  
4 while(cursor.hasNext()) {  
5     System.out.println(cursor.next());  
6 }
```

## Requête

```
1 BasicDBObject query = new BasicDBObject();
2 List<Integer> list = new ArrayList<Integer>();
3 list.add(9);
4 list.add(10);
5 query.put("number", new BasicDBObject("$in", list));
6 DBCursor cursor = collection.find(query);
7 while(cursor.hasNext()) {
8     System.out.println(cursor.next());
9 }
```

## Requête

```
1 BasicDBObject query = new BasicDBObject();  
2 query.put("number", new BasicDBObject("$gt", 5));  
3 DBCursor cursor = collection.find(query);  
4 while(cursor.hasNext()) {  
5     System.out.println(cursor.next());  
6 }
```

## Requête

```
BasicDBObject query = new BasicDBObject();
query.put("number", new BasicDBObject("$gt", 5).append("$lt", 8));
DBCursor cursor = collection.find(query);
while(cursor.hasNext()) {
    System.out.println(cursor.next());
}
```

## Requête

```
1 BasicDBObject query5 = new BasicDBObject();  
2 query5.put("number", new BasicDBObject("$ne", 8));  
3 DBCursor cursor6 = collection.find(query5);  
4 while(cursor6.hasNext()) {  
5     System.out.println(cursor6.next());  
6 }
```

## Création d'un index

```
coll.createIndex(new BasicDBObject("i", 1)); // create index on "i", ascending
```

## Requête

```
import java.net.UnknownHostException;
import java.util.ArrayList;
import java.util.List;
import com.mongodb.*;

/**
 * Java MongoDB : Query document
 */
public class QueryDocumentApp {
    public static void main(String[] args) {
        try {
            Mongo mongo = new Mongo("localhost", 27017);
            DB db = mongo.getDB("yourdb");

            // get a single collection
            DBCollection collection = db.getCollection("dummyColl");

            // insert number 1 to 10 for testing
            for (int i = 1; i <= 10; i++) {
                collection.insert(new BasicDBObject().append("number", i));
            }
            // ....
            System.out.println("Done");
        } catch (UnknownHostException e) {
            e.printStackTrace();
        } catch (MongoException e) {
            e.printStackTrace();
        }
    }
}
```



# Conclusion

## Vous savez...

- ...utiliser MongoDB
- ...en JAVA

## Il faut...

- ...finir le MySQL (servlet User + Friends)
- ...intégrer MongoDB au site actuel (servlet MESSAGES)
  - ▶ ...Définir un "format" de stockage des commentaires
  - ▶ ...Implémenter les servlets de "recherche" des commentaires récents

## Vous ne savez pas...

- ...faire un moteur par recherche de mots-clefs
- à base de Map/Reduce
- ... plus tard